

El impacto del Teorema de Bayes y los clasificadores probabilísticos en la minería de datos y el aprendizaje automático

La evolución de la minería de datos y el aprendizaje automático ha estado intrínsecamente ligada al desarrollo de marcos estadísticos que permiten a los sistemas computacionales razonar bajo condiciones de incertidumbre. En el centro de este paradigma se encuentra el Teorema de Bayes, una proposición matemática que no solo constituye una piedra angular de la estadística moderna, sino que ha dado lugar a una familia de clasificadores que definen la eficiencia en el procesamiento de información masiva.¹ La relación entre el Teorema de Bayes y los clasificadores en Machine Learning se manifiesta como un puente entre la teoría de la probabilidad clásica y la capacidad predictiva de los algoritmos contemporáneos, permitiendo que las máquinas actualicen sus "creencias" iniciales a medida que se integran nuevas evidencias provenientes de los datos.²

Fundamentos de la inferencia bayesiana en el aprendizaje automático

La inferencia bayesiana se distingue de otros enfoques estadísticos por su tratamiento de la probabilidad como un grado de creencia que puede ser actualizado.⁴ En la minería de datos, este proceso de actualización es fundamental para el aprendizaje supervisado, donde el objetivo es predecir la etiqueta de clase de una instancia basándose en sus atributos.⁶ El Teorema de Bayes proporciona la regla matemática para realizar esta transición de una probabilidad a priori a una probabilidad a posteriori.²

La mecánica del Teorema de Bayes

La expresión formal del teorema se articula mediante la relación entre cuatro componentes críticos: la probabilidad a posteriori, la verosimilitud (likelihood), la probabilidad a priori (prior) y la evidencia.² Matemáticamente, para una hipótesis H y una evidencia D , la relación se expresa como:

$$P(H|D) = \frac{P(D|H)P(H)}{P(D)}$$

En el contexto de la minería de datos, H representa la clase que intentamos predecir (por

ejemplo, si un correo es "spam" o "no spam") y D representa el vector de características u observaciones (las palabras contenidas en el correo).⁸ El término $P(H)$ es el conocimiento previo que tenemos sobre la frecuencia de las clases en el conjunto de entrenamiento; si sabemos que el 80% de los correos recibidos históricamente son legítimos, nuestro "prior" para la clase "no spam" será 0.8.²

El componente $P(D|H)$, la verosimilitud, indica cuán probable es observar los datos D dado que la hipótesis H es cierta. Durante la fase de entrenamiento, el algoritmo analiza los datos etiquetados para construir un modelo de estas probabilidades.⁶ Finalmente, el resultado $P(H|D)$ es la probabilidad a posteriori, que indica la confianza del modelo en que una instancia pertenezca a una clase específica tras haber analizado sus atributos.⁸

Componente Bayesiano	Definición Estadística	Significado en Machine Learning
Probabilidad a Priori	$P(C_i)$	Frecuencia relativa de la clase C_i en los datos de entrenamiento.
Verosimilitud	$P(X C_i)$	Probabilidad de observar el vector de atributos X en la clase C_i .
Evidencia	$P(X)$	Probabilidad total de observar el vector X en todo el espacio muestral.
Probabilidad a Posteriori	$P(C_i X)$	Probabilidad actualizada de que X pertenezca a C_i tras

		ver los datos.
--	--	----------------

Este marco de trabajo permite que los clasificadores bayesianos manejen la incertidumbre de manera nativa. A diferencia de los clasificadores discriminativos que simplemente trazan una frontera de decisión (como las máquinas de vectores de soporte), los clasificadores bayesianos son modelos generativos que intentan modelar cómo se distribuyen los datos dentro de cada clase.¹¹

El clasificador Naive Bayes: La simplificación estratégica

A pesar de la elegancia del Teorema de Bayes, su aplicación directa en conjuntos de datos con múltiples atributos presenta un desafío computacional significativo. Para calcular $P(X|C_i)$ donde X es un vector de n atributos $(x_1, x_2, \dots, x_n)$, sería necesario modelar la distribución conjunta de todas las variables, lo que requeriría una cantidad impracticable de datos y tiempo de procesamiento.¹⁴ Aquí es donde surge el clasificador Naive Bayes (o Bayes Ingenuo), introduciendo una suposición simplificadora: la independencia condicional de los atributos.¹⁶

El supuesto de independencia condicional

El término "ingenuo" proviene de la suposición de que el efecto de un atributo sobre una clase dada es independiente de los valores de otros atributos.⁸ Bajo esta premisa, la verosimilitud conjunta se simplifica al producto de las probabilidades individuales:

$$P(x_1, x_2, \dots, x_n | C_i) = P(x_1 | C_i) \times P(x_2 | C_i) \times \dots \times P(x_n | C_i) = \prod_{k=1}^n P(x_k | C_i)$$

Esta simplificación transforma un problema de complejidad exponencial en uno de complejidad lineal, permitiendo que el clasificador se entrene de manera extremadamente eficiente incluso en conjuntos de datos de alta dimensión, como la clasificación de textos con miles de palabras únicas.¹⁰

La paradoja del rendimiento de Naive Bayes

Resulta fascinante observar que, aunque la suposición de independencia es casi siempre violada en el mundo real —donde las palabras en una oración están relacionadas o los síntomas médicos coexisten—, el clasificador Naive Bayes a menudo ofrece un rendimiento competitivo frente a algoritmos mucho más complejos como los bosques aleatorios o las redes

neuronales.¹²

Investigaciones en el campo de la minería de datos sugieren que esto se debe a la función de pérdida de "cero-uno" utilizada en las tareas de clasificación.¹² Mientras que las estimaciones de probabilidad individuales pueden ser inexactas debido a la falta de independencia, el orden relativo de las probabilidades de las clases suele preservarse. En otras palabras, mientras el clasificador asigne la probabilidad más alta a la clase correcta, la predicción será acertada, independientemente de si el valor numérico exacto de la probabilidad está sesgado.¹² Además, Naive Bayes es un modelo de "alto sesgo y baja varianza", lo que lo hace excepcionalmente robusto frente al ruido y capaz de generalizar bien a partir de conjuntos de datos de entrenamiento relativamente pequeños.²⁰

Variantes del clasificador Naive Bayes según la naturaleza de los datos

La minería de datos moderna requiere el manejo de diversos tipos de variables, desde recuentos discretos hasta mediciones continuas. Para abordar esta diversidad, el algoritmo Naive Bayes se implementa en varias variantes, cada una asumiendo una distribución de probabilidad distinta para los atributos.⁷

Naive Bayes Gaussiano

Esta variante se utiliza primordialmente cuando los atributos son variables continuas que siguen una distribución normal o de campana de Gauss.⁵ El algoritmo calcula la media (μ) y la desviación estándar (σ) de cada atributo para cada clase durante el entrenamiento.⁵ Para una nueva instancia, la probabilidad de un valor x se estima mediante la función de densidad de probabilidad gaussiana:

$$f(x; \mu, \sigma) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Es el modelo predilecto para aplicaciones de diagnóstico médico basadas en mediciones biométricas o en la clasificación de señales de sensores industriales.¹²

Naive Bayes Multinomial

El clasificador multinomial es la piedra angular de la minería de textos y la categorización de documentos.⁷ En este modelo, los datos representan recuentos de frecuencia de eventos, como la cantidad de veces que aparece una palabra específica en un artículo.⁷ Es especialmente eficaz para distinguir entre temas (por ejemplo, deportes frente a política) basándose en el vocabulario dominante.²⁴

Naive Bayes de Bernoulli

A diferencia del modelo multinomial, la variante de Bernoulli se centra en variables binarias o booleanas.¹⁶ No considera cuántas veces aparece una característica, sino únicamente si está presente (1) o ausente (0).⁵ Esta variante es extremadamente popular en el filtrado de spam y en el análisis de sentimiento de textos cortos como mensajes de redes sociales, donde la presencia de ciertos términos (como "estafa" o "increíble") es más informativa que su repetición.⁵

Naive Bayes de Complemento (CNB)

Uno de los avances más significativos para abordar el desequilibrio de clases en minería de datos es el Complement Naive Bayes. En muchos escenarios reales, como la detección de fraude financiero o el diagnóstico de enfermedades raras, una clase es significativamente más pequeña que la otra.²⁹ Los modelos multinomiales estándar tienden a estar sesgados hacia la clase mayoritaria.

El CNB soluciona este problema calculando las probabilidades basadas en el "complemento" de cada clase.²⁹ En lugar de preguntar "¿cuál es la probabilidad de esta palabra dada la clase A?", el algoritmo pregunta "¿cuál es la probabilidad de esta palabra dadas todas las clases que NO son A?".³⁰ Al modelar lo que una clase no es, el algoritmo obtiene estimaciones de parámetros mucho más justas y precisas para las clases minoritarias.²⁹

Variante	Tipo de Distribución	Aplicación Ideal	Comportamiento con Big Data
Gaussiano	Normal (Continua)	Mediciones físicas, sensores.	Requiere cálculo de media/varianza.
Multinomial	Multinomial (Conteos)	Clasificación de documentos extensos.	Altamente escalable en NLP.
Bernoulli	Binaria (Presencia)	Spam, textos cortos, microblogs.	Muy eficiente en memoria.

Complement	Basada en el complemento	Datos muy desequilibrados (Fraude).	Robusta ante sesgos de clase.
------------	--------------------------	-------------------------------------	-------------------------------

Desafíos técnicos y estrategias de optimización en la implementación

La aplicación práctica de los clasificadores bayesianos en entornos de producción exige el manejo de varios problemas numéricos y estadísticos que pueden degradar el rendimiento del modelo si no se gestionan adecuadamente.⁷

El problema de la probabilidad cero y el suavizado de Laplace

Un problema crítico en Naive Bayes ocurre cuando un atributo en los datos de prueba tiene un valor que nunca se observó en los datos de entrenamiento para una clase determinada. Dado que el algoritmo multiplica las probabilidades, un solo valor de cero anulará toda la

probabilidad a posteriori de la clase ($0 \times P_1 \times P_2 \dots = 0$), invalidando la predicción.¹⁰

Para solucionar esto, se emplea el suavizado de Laplace (Laplacian Smoothing), que consiste

en añadir un pequeño valor positivo (el parámetro α , usualmente 1) a todos los recuentos durante el cálculo de las probabilidades.⁵ Esto asegura que ninguna probabilidad sea exactamente cero, permitiendo que el clasificador mantenga su capacidad de decisión incluso ante términos nuevos o raros.⁵

Estabilidad numérica y el uso de logaritmos

En conjuntos de datos con cientos o miles de características, la multiplicación de muchas probabilidades pequeñas (todas entre 0 y 1) puede resultar en números extremadamente cercanos a cero que superan la precisión de los procesadores modernos (subdesbordamiento o numerical underflow).¹⁵ La práctica estándar en la ingeniería de aprendizaje automático es realizar los cálculos en el espacio logarítmico.¹⁵ Al aplicar el logaritmo, las multiplicaciones se convierten en sumas:

$$\log(P(C) \prod P(x_i|C)) = \log(P(C)) + \sum \log(P(x_i|C))$$

Esto no solo previene errores numéricos, sino que también suele acelerar el tiempo de cómputo, ya que las sumas son operaciones más sencillas para la CPU que las multiplicaciones de punto flotante.¹⁵

Redes Bayesianas de Creencia: Modelando la complejidad causal

Mientras que Naive Bayes asume una independencia total, las Redes Bayesianas de Creencia (BBN) permiten representar dependencias condicionales explícitas entre variables.¹⁵ Estas redes utilizan una estructura de Grafo Acíclico Dirigido (DAG) para modelar relaciones de causa y efecto, donde los nodos representan variables aleatorias y los arcos indican una influencia probabilística directa.³²

Arquitectura de una Red Bayesiana

A diferencia de la estructura "plana" de Naive Bayes, las BBN permiten una jerarquía de dependencias.¹⁵ Si una variable B depende de A , pero C depende de B , la red captura esta cadena de influencia. Cada nodo en la red está equipado con una Tabla de Probabilidad Condicional (CPT) que define la probabilidad de cada estado de la variable dados los estados de sus "padres" en el grafo.¹⁵

Esta capacidad de modelado hace que las BBN sean herramientas excepcionales para sistemas de apoyo a la decisión donde las relaciones no son simples.³² Por ejemplo, en el diagnóstico médico, una red puede modelar cómo la "edad" influye en la "presión arterial", y cómo esta última, junto con el "tabaquismo", afecta la probabilidad de "enfermedad cardíaca".³⁴

Comparativa de capacidades de modelado

La elección entre un modelo Naive y una Red Bayesiana completa depende del equilibrio entre la precisión requerida y la cantidad de datos disponibles.³³

Atributo	Naive Bayes	Redes Bayesianas (BBN)
Complejidad	Baja; entrenamiento instantáneo.	Alta; requiere algoritmos de optimización.
Requisito de Datos	Bajo; funciona bien con muestras pequeñas.	Alto; necesita muchos datos para estimar CPTs.
Flexibilidad	Rígida (asunción de	Alta (modela cualquier

	independencia).	dependencia).
Interpretabilidad	Alta (probabilidades de atributos).	Muy Alta (permite análisis de causalidad).
Casos de Uso	Spam, clasificación rápida de textos.	Diagnóstico clínico complejo, fallos de ingeniería.

Aplicaciones industriales de alto impacto

La integración de los clasificadores bayesianos en la minería de datos ha transformado industrias enteras al proporcionar un método confiable para automatizar la toma de decisiones.¹

Filtrado de spam y seguridad de la información

El filtrado de correo no deseado es quizás la aplicación más emblemática de Naive Bayes.⁸ Los sistemas modernos no solo buscan palabras clave, sino que analizan la estructura del mensaje, la reputación del remitente y el contexto temporal.² Al ser un sistema de aprendizaje supervisado, el clasificador se actualiza continuamente: cada vez que un usuario marca un correo como spam, el modelo recalcula las probabilidades de los términos contenidos en ese mensaje, refinando su precisión para futuros envíos.¹

Minería de datos en salud y bioinformática

En el sector sanitario, la estadística bayesiana es vital debido a su capacidad para manejar la prevalencia de enfermedades.³ Un resultado positivo en una prueba diagnóstica debe interpretarse siempre a la luz de la probabilidad previa de que el paciente tenga la enfermedad (la tasa base).² Los clasificadores bayesianos evitan el error de diagnóstico al integrar formalmente la sensibilidad de la prueba, su especificidad y la prevalencia poblacional.²

En 2024 y 2025, se observa un auge en el uso de Redes Bayesianas para la oncología de precisión, donde se integran datos genómicos, resultados de imagenología y factores de estilo de vida para predecir la respuesta a tratamientos específicos para cánceres como el de esófago o páncreas.³⁷

Análisis de sentimiento y experiencia del cliente

Las empresas de marketing utilizan clasificadores bayesianos para procesar flujos masivos de

datos provenientes de reseñas de productos y redes sociales.¹⁷ Estos modelos categorizan las opiniones en sentimientos positivos, negativos o neutros con una eficiencia que permite a las marcas reaccionar a crisis de reputación en cuestión de minutos.³⁸ A pesar de que Naive Bayes ignora el orden de las palabras (modelo de "bolsa de palabras"), su capacidad para detectar el tono emocional general lo hace indispensable para el monitoreo de marca a gran escala.¹⁷

Detección de anomalías y ciberseguridad

En la protección de infraestructuras críticas, los clasificadores bayesianos se utilizan para identificar comportamientos inusuales en las redes.⁴¹ Mediante la comparación de las acciones actuales de un usuario con su perfil histórico (su "prior"), el sistema puede calcular la probabilidad de que una sesión sea maliciosa.⁴² Esto es especialmente útil para detectar amenazas internas o exfiltración de datos, donde las acciones individuales pueden parecer legítimas pero la combinación probabilística de las mismas resulta altamente sospechosa.⁴²

Minería de datos a gran escala: Spark, Hadoop y Bayes

La simplicidad matemática de los clasificadores bayesianos los convierte en candidatos ideales para el procesamiento de Big Data.³¹ Dado que el entrenamiento solo requiere el conteo de frecuencias y el cálculo de promedios, estas tareas pueden dividirse fácilmente entre miles de nodos de computación.⁴³

Implementación distribuida con Apache Spark

El módulo MLlib de Apache Spark proporciona una implementación altamente optimizada de Naive Bayes Multinomial y de Bernoulli.³¹ Spark aprovecha la computación en memoria para procesar conjuntos de datos que superan la capacidad de un solo servidor, permitiendo entrenar modelos sobre petabytes de datos de texto o registros de transacciones en tiempos reducidos.⁴⁴ La arquitectura MapReduce de Hadoop también se ha utilizado históricamente para este propósito, aunque la velocidad de Spark lo ha desplazado en la mayoría de las aplicaciones de minería de datos en tiempo real.⁴³

El futuro: Computación perimetral e IA ligera (2025-2026)

Hacia el año 2025, la tendencia de la minería de datos se desplaza desde los grandes centros de datos hacia el "Edge" o borde de la red.⁴⁶ Con más de 75 mil millones de dispositivos IoT previstos, la necesidad de realizar clasificaciones localmente en sensores, cámaras y dispositivos médicos es imperativa.⁴⁶

Los clasificadores bayesianos, debido a su bajísima huella de memoria y requisitos de procesamiento mínimos, están experimentando un renacimiento en la computación perimetral.⁴⁶ Mientras que las redes neuronales profundas requieren GPUs potentes y mucha energía, un clasificador Naive Bayes puede ejecutarse en microcontroladores simples, permitiendo que dispositivos de bajo costo tomen decisiones inteligentes de manera

autónoma.⁴⁷

Consideraciones éticas y limitaciones del paradigma

A pesar de sus múltiples ventajas, los profesionales de la minería de datos deben ser conscientes de las limitaciones de los métodos bayesianos.⁶ La calidad de la predicción depende enteramente de la calidad de las probabilidades a priori y de la veracidad de las suposiciones de distribución.⁶

Un riesgo latente es la perpetuación de sesgos si las probabilidades a priori reflejan desigualdades históricas en lugar de realidades objetivas.² Asimismo, el exceso de confianza de Naive Bayes —que tiende a producir probabilidades a posteriori muy cercanas a 0 o 1 debido a la multiplicación de factores— puede ser peligroso en aplicaciones donde la cuantificación precisa de la incertidumbre es vital.¹⁶ En tales casos, se prefieren las Redes Bayesianas completas o los métodos de calibración de modelos.¹⁵

Conclusión: La resiliencia del pensamiento probabilístico

La relación entre el Teorema de Bayes y los clasificadores representa una de las historias de éxito más duraderas en la minería de datos y el aprendizaje automático. Su capacidad para ofrecer soluciones rápidas, escalables e interpretables ha garantizado su relevancia frente a olas sucesivas de tecnologías más complejas.¹ Desde la clasificación de estrellas en astronomía hasta la detección de fraudes financieros en tiempo real, la lógica de Thomas Bayes continúa proporcionando el marco necesario para convertir los datos brutos en conocimiento accionable.⁴

En última instancia, la vigencia de estos clasificadores no reside en su perfección matemática, sino en su utilidad pragmática. Como modelos de "aproximación útil", los clasificadores bayesianos demuestran que, a menudo, una estructura simple y robusta es preferible a una compleja y frágil en el ruidoso e impredecible mundo de los datos reales.²⁰ Con la llegada de la IA perimetral y la necesidad de modelos más eficientes energéticamente para 2026, el paradigma bayesiano está posicionado para seguir siendo un pilar fundamental de la minería de datos por las décadas venideras.⁴⁶

Obras citadas

1. Qué es el Teorema de Bayes y su importancia en Machine Learning - El blog de Kraz, fecha de acceso: mayo 13, 2026, <https://blog.kraz.ai/all/que-es-el-teorema-de-bayes-y-que-importancia-tiene-en-machine-learning/>
2. Bayes' Theorem in Real Life: From Spam Filters to Medical Diagnosis | by Nirvan Uttamchandani | Medium, fecha de acceso: mayo 13, 2026, <https://medium.com/@nirvan.uttamchandani99/bayes-theorem-in-real-life-from->

- [spam-filters-to-medical-diagnosis-85b8183bc295](#)
3. EL TEOREMA DE BAYES !EXPLICADO! - YouTube, fecha de acceso: mayo 13, 2026, <https://www.youtube.com/watch?v=3vtS2qc4t6o>
 4. Teorema de Bayes - Wikipedia, la enciclopedia libre, fecha de acceso: mayo 13, 2026, https://es.wikipedia.org/wiki/Teorema_de_Bayes
 5. Understanding Naive Bayes from Scratch: Theory, Math, and Worked Examples | by Abinaya Subramaniam | AI Simplified in Plain English | Medium, fecha de acceso: mayo 13, 2026, <https://medium.com/ai-simplified-in-plain-english/understanding-naive-bayes-from-scratch-theory-math-and-worked-examples-8819d3cf6894>
 6. Bayes Classification - GeeksforGeeks, fecha de acceso: mayo 13, 2026, <https://www.geeksforgeeks.org/machine-learning/bayes-classification/>
 7. Naive Bayes: clasificación probabilística por medida - Konfuzio, fecha de acceso: mayo 13, 2026, <https://konfuzio.com/es/bayas-ingenuas/>
 8. ¿Qué son los clasificadores Naive Bayes? - IBM, fecha de acceso: mayo 13, 2026, <https://www.ibm.com/es-es/think/topics/naive-bayes>
 9. Spam Filtering Using Bayesian Theorem - Kaggle, fecha de acceso: mayo 13, 2026, <https://www.kaggle.com/code/rashimishra19/spam-filtering-using-bayesian-theorem>
 10. Tutorial sobre el clasificador bayesiano ingenuo: con Python Scikit-learn | DataCamp, fecha de acceso: mayo 13, 2026, <https://www.datacamp.com/es/tutorial/naive-bayes-scikit-learn>
 11. What Are Naïve Bayes Classifiers? - IBM, fecha de acceso: mayo 13, 2026, <https://www.ibm.com/think/topics/naive-bayes>
 12. Naive Bayes | TrendSpider Learning Center, fecha de acceso: mayo 13, 2026, <https://trendspider.com/learning-center/naive-bayes/>
 13. Comparison between Naive Bayes algorithms and Bayesian machine learning techniques - Practical Electron Microscopy and Database, fecha de acceso: mayo 13, 2026, <https://www.globalsino.com/ICs/page3383.html>
 14. Teorema de Bayes en el aprendizaje automático: una guía importante - Ciberseguridad, fecha de acceso: mayo 13, 2026, <https://ciberseguridad.com/guias/nuevas-tecnologias/machine-learning/teorema-bayes/>
 15. BAYESIAN CLASSIFICATION, fecha de acceso: mayo 13, 2026, <https://www3.cs.stonybrook.edu/~cse521/19Bayes.pdf>
 16. Naive Bayes classifier - Wikipedia, fecha de acceso: mayo 13, 2026, https://en.wikipedia.org/wiki/Naive_Bayes_classifier
 17. Naive Bayes Algorithm Explained – Uses & Applications 2026 - upGrad, fecha de acceso: mayo 13, 2026, <https://www.upgrad.com/blog/naive-bayes-explained/>
 18. Naive Bayes: Types and Applications - Keylabs, fecha de acceso: mayo 13, 2026, <https://keylabs.ai/blog/naive-bayes-classifiers-types-and-use-cases/>
 19. Naive Bayes - University of Washington, fecha de acceso: mayo 13, 2026, <http://aiweb.cs.washington.edu/ai/naive.html>
 20. Why Naive Bayes Works Surprisingly Well (Even When Its Assumptions Are

- Wrong) | by Sanskriti Sharma | Medium, fecha de acceso: mayo 13, 2026,
<https://medium.com/@sanskritisharma1822/why-naive-bayes-works-surprisingly-well-even-when-its-assumptions-are-wrong-af68d6d062c4>
21. Clasificador bayesiano ingenuo - Wikipedia, la enciclopedia libre, fecha de acceso: mayo 13, 2026,
https://es.wikipedia.org/wiki/Clasificador_bayesiano_ingenuo
 22. Why does Naive Bayes work better when the number of features >> sample size compared to more sophisticated ML algorithms? - Stats StackExchange, fecha de acceso: mayo 13, 2026,
<https://stats.stackexchange.com/questions/379383/why-does-naive-bayes-work-better-when-the-number-of-features-sample-size-comp>
 23. The Difference Between Categorical, Multinomial, Bernoulli, and Gaussian Naive Bayes Classification - James D. McCaffrey, fecha de acceso: mayo 13, 2026,
<https://jamesmccaffrey.wordpress.com/2023/04/13/the-difference-between-categorical-multinomial-bernoulli-and-gaussian-naive-bayes-classification/>
 24. Performance Comparison between Naive Bayes and Machine ..., fecha de acceso: mayo 13, 2026, <https://www.intechopen.com/chapters/1154729>
 25. 02.1 Clasificación naive-Bayes — Introducción al Aprendizaje Automático - UPM, fecha de acceso: mayo 13, 2026,
https://dcain.etsin.upm.es/~carlos/bookAA/02.1_MetodosdeClasificacion-Naive-Bayes.html
 26. Difference between Binomial, Multinomial and Bernoulli Naive Bayes Classifiers? - Reddit, fecha de acceso: mayo 13, 2026,
https://www.reddit.com/r/MachineLearning/comments/2uhhbh/difference_between_binomial_multinomial_and/
 27. ¿Qué son los clasificadores Naive Bayes? - IBM, fecha de acceso: mayo 13, 2026,
<https://www.ibm.com/mx-es/think/topics/naive-bayes>
 28. Filtrado bayesiano de spam - Wikipedia, la enciclopedia libre, fecha de acceso: mayo 13, 2026, https://es.wikipedia.org/wiki/Filtrado_bayesiano_de_spam
 29. Complement Naive Bayes (CNB) Algorithm - GeeksforGeeks, fecha de acceso: mayo 13, 2026,
<https://www.geeksforgeeks.org/machine-learning/complement-naive-bayes-cnb-algorithm/>
 30. Complement Naive Bayes (CNB) Algorithm (math clearly explained ..., fecha de acceso: mayo 13, 2026,
<https://medium.com/@tarunsaxena1000/complement-naive-bayes-cnb-algorithm-af7b5d2872bb>
 31. Naive Bayes - RDD-based API - Spark 4.1.1 Documentation, fecha de acceso: mayo 13, 2026, <https://spark.apache.org/docs/latest/mllib-naive-bayes.html>
 32. Naive Bayes and Bayesian Networks - the intact one, fecha de acceso: mayo 13, 2026, <https://theintactone.com/2023/01/22/naive-bayes-and-bayesian-networks/>
 33. Simple Explanation-Difference between Naive Bayes and Full Bayesian Network Model, fecha de acceso: mayo 13, 2026,
<https://medium.com/@mansi89mahi/simple-explanation-difference-between-naive-bayes-and-full-bayesian-network-model-505616545503>

34. Redes bayesianas y diagnóstico médico. Una ... - PoliPapers - UPV, fecha de acceso: mayo 13, 2026,
<https://polipapers.upv.es/index.php/MSEL/article/download/10830/11695>
35. What is the difference between a Bayesian network and a naive Bayes classifier?, fecha de acceso: mayo 13, 2026,
<https://stackoverflow.com/questions/12298150/what-is-the-difference-between-a-bayesian-network-and-a-naive-bayes-classifier>
36. Bayesian Classification in Data Mining- Scaler Topics, fecha de acceso: mayo 13, 2026,
<https://www.scaler.com/topics/data-mining-tutorial/bayesian-classification-in-data-mining/>
37. Comprehensive review of Bayesian network applications in gastrointestinal cancers - PMC, fecha de acceso: mayo 13, 2026,
<https://pmc.ncbi.nlm.nih.gov/articles/PMC12198876/>
38. Naive BayesInsight: Website Sentiment Classification - Hyper Intelligence SEO - ThatWare, fecha de acceso: mayo 13, 2026,
<https://thatware.co/naive-bayesinsight-website-sentiment-classification/>
39. Social Media Sentiment Analysis Using Naïve Bayes & SVM - upGrad, fecha de acceso: mayo 13, 2026,
<https://www.upgrad.com/blog/social-media-sentiment-analysis/>
40. ¿Qué es el análisis de sentimiento? Guía técnica exhaustiva - Elastic, fecha de acceso: mayo 13, 2026, <https://www.elastic.co/es/what-is/sentiment-analysis>
41. A Novel Ensemble of Deep Learning Approach for Cybersecurity ..., fecha de acceso: mayo 13, 2026, <https://www.mdpi.com/2076-3417/15/14/7984>
42. Advanced modelling techniques for anomaly detection: A proactive ..., fecha de acceso: mayo 13, 2026,
https://ijsra.net/sites/default/files/fulltext_pdf/IJSRA-2024-2511.pdf
43. Distributed Naive Bayes Text Classification Using Hadoop and Word Embedding - Atlantis Press, fecha de acceso: mayo 13, 2026,
<https://www.atlantis-press.com/article/25850121.pdf>
44. Why Apache Spark Outshines Hadoop in Big Data Processing | by Gad August | Medium, fecha de acceso: mayo 13, 2026,
<https://medium.com/@gadnwachukwu2/why-apache-spark-outshines-hadoop-in-big-data-processing-b47dbeabb049>
45. Distributed Machine Learning using HDFS and Apache Spark for Big Data Challenges, fecha de acceso: mayo 13, 2026,
https://www.e3s-conferences.org/articles/e3sconf/abs/2023/102/e3sconf_icimece2023_02058/e3sconf_icimece2023_02058.html
46. Edge Compute Case Study: Winning Strategies For 2025 - Troy Lendman, fecha de acceso: mayo 13, 2026,
<https://troylendman.com/edge-compute-case-study-winning-strategies-for-2025/>
47. Top 10 Edge Computing Use Cases and Applications Across Industries - - Codewave, fecha de acceso: mayo 13, 2026,
<https://codewave.com/insights/edge-computing-use-cases-applications/>

48. Boruah A. Embedded Artificial Intelligence. Real-Life Apps and Case Studies 2025
- Scribd, fecha de acceso: mayo 13, 2026,
<https://www.scribd.com/document/840586473/Boruah-A-Embedded-Artificial-Intelligence-Real-Life-Apps-and-Case-Studies-2025>
49. Naive Bayes Algorithm: Origins, Real-World Applications, and Case Studies, fecha de acceso: mayo 13, 2026,
https://dev.to/vamshi_e_eebe5a6287a27142/naive-bayes-algorithm-origins-real-world-applications-and-case-studies-4dhd