

Manual de Usuario

Pipeline CRISP-DM: Opinión sobre la Vacuna de Influenza

1. Introducción

Este manual describe el procedimiento paso a paso para operar el pipeline de minería de datos diseñado para analizar la opinión ciudadana sobre la vacuna contra la influenza en México a partir de la plataforma Reddit. El sistema consta de 8 fases secuenciales.

2. Requisitos Previos

Antes de ejecutar cualquier script, asegúrese de contar con lo siguiente:

- Instalación de Python 3.8 o superior.
- Conexión a internet estable (requerida para el scraping y la descarga de modelos BERT/spaCy).
- Suficiente espacio en disco para el almacenamiento de matrices dispersas y modelos.

3. Flujo de Ejecución (Paso a Paso)

Ejecute los scripts en el siguiente orden estricto desde su terminal o consola de comandos:

Paso 1: Recolección de Datos (Scraping)

Comando: `python scraper_influenza_vacuna_v3.py`

Descripción: Extrae comentarios de Reddit utilizando términos de búsqueda relacionados con la vacuna. Funciona en bloques interactivos y guarda un archivo JSON al finalizar o al presionar Ctrl+C.

Salida: `dataset_nodoB_capacidad_hospitalaria_*.json`

Paso 2: Limpieza y Filtrado

Comando: `python limpiar_dataset_vacuna_v6.py`

Descripción: El script le pedirá seleccionar el archivo JSON obtenido en el Paso 1. Se encargará de eliminar bots, convertir emojis a texto, filtrar comentarios cortos y priorizar aquellos relevantes a la vacunación.

Salida: `dataset_limpio_*.json`

Paso 3: Enriquecimiento de Datos

Comando: `python enriqueser.py`

Descripción: Seleccione el archivo limpio generado en el paso anterior. Este paso calcula el Índice de Fricción Burocrática (IFB) y detecta la polaridad local (jerga mexicana) y posturas explícitas sobre la vacuna.

Salida: `dataset_enriquecido_*.json`

Paso 4: Auto-Etiquetado con Inteligencia Artificial

Comando: `python auto_etiquetar.py`

Descripción: Utiliza el modelo de lenguaje RoBERTa para evaluar el sentimiento de cada comentario (Positivo, Negativo, Neutro) de forma automática. Además, crea una "cola de revisión" para casos ambiguos.

Salida: `dataset_etiquetado_*.json` (y opcionalmente `cola_revision_*.json`).

Paso 5: Normalización Lingüística (NLP)

Comando: `python normalizar_nlp_v3.py`

Descripción: Procesa el texto etiquetado para extraer raíces de palabras (lematización) y encontrar entidades como nombres de hospitales, respetando palabras clave como los "no" rotundos.

Salida: `dataset_normalizado_*.json`

Paso 6: Vectorización Numérica

Comando: `python vectorizar_v4.py`

Descripción: Convierte los textos en números para que el modelo predictivo pueda entenderlos. Le preguntará qué estrategia usar (se recomienda la Estrategia E: Híbrida BERT + TF-IDF).

Salidas: Archivos `.npz`, `.npy` y un `.pkl`.

Paso 7: Entrenamiento y Evaluación del Modelo

Comando: `python analizar_v4.py`

Descripción: Entrena el ensamble de clasificadores (VotingEnsemble) para detectar ineficiencias y posturas. Seleccione los archivos generados en el Paso 6.

Salidas: Reportes estadísticos JSON y gráficos PNG (Matriz de confusión y Heatmap).

Paso 8: Generación de Tablero Visual (Infografía)

Comando: `python infografia_html.py`

Descripción: Busca automáticamente los resultados del Paso 7 y genera un panel de control visual.

Salida: Un archivo `infografia_vacuna_v4_*.html` que puede abrir con cualquier navegador web para ver los resultados.

Aviso Importante: El flujo debe ser secuencial. Si algún paso falla, revise los mensajes en la consola. Un error común es no seleccionar el archivo correcto de la fase inmediatamente anterior.