



Estadística y metodología CRISP-DM en Minería de Datos

José Emmanuel Muñoz de Jesús

Benemérita Universidad Autónoma de Puebla

Materia: Minería de Datos

13 de mayo de 2026

1 ¿Qué es la estadística?

La estadística es la ciencia que se ocupa de recolectar, organizar, presentar, analizar e interpretar datos numéricos con el fin de tomar decisiones o extraer conclusiones en condiciones de incertidumbre. En minería de datos actúa como el lenguaje fundamental para describir las variables, detectar patrones, limpiar irregularidades y validar modelos. Se divide en dos grandes ramas:

- **Estadística descriptiva:** resume y describe las características principales de un conjunto de datos mediante tablas, gráficos y medidas numéricas (tendencia central, dispersión, forma).
- **Estadística inferencial:** utiliza los datos de una muestra para estimar parámetros, probar hipótesis y hacer predicciones sobre la población de origen.

2 Metodología CRISP-DM

CRISP-DM (Cross-Industry Standard Process for Data Mining) es un modelo de proceso estándar, no propietario, que guía la ejecución de proyectos de minería de datos. Se compone de seis fases interactivas e iterativas:

1. **Comprensión del negocio:** definir objetivos, requisitos y criterios de éxito desde la perspectiva del problema real.
2. **Comprensión de los datos:** recopilar los datos iniciales, describirlos, explorarlos y verificar su calidad. Aquí se aplican la estadística descriptiva y las visualizaciones (histogramas, diagramas de caja, etc.).
3. **Preparación de los datos:** limpiar, transformar, integrar y formatear los datos para construir la tabla final que alimentará los modelos.
4. **Modelado:** seleccionar, entrenar y ajustar algoritmos de aprendizaje automático (clasificación, regresión, agrupamiento, etc.).
5. **Evaluación:** revisar si los modelos cumplen los objetivos del negocio y si son válidos antes de su despliegue.
6. **Despliegue:** poner en producción el conocimiento obtenido, por ejemplo mediante informes, aplicaciones o procesos automatizados.

Las técnicas estadísticas explicadas a continuación se insertan sobre todo en las fases de *Comprensión de los datos* y *Preparación de los datos*.

3 Análisis descriptivo para un conjunto de datos

Para ilustrar cada concepto utilizaremos el siguiente conjunto de datos correspondiente a las edades (en años) de 15 personas que participaron en una encuesta de salud:

45, 52, 61, 72, 55, 49, 63, 58, 67, 71, 59, 48, 55, 64, 70

3.1 Medidas de tendencia central

Indican el valor alrededor del cual se agrupan los datos.

- **Media** ($\bar{x}$): promedio aritmético.

$$\bar{x} = \frac{45 + 52 + 61 + 72 + 55 + 49 + 63 + 58 + 67 + 71 + 59 + 48 + 55 + 64 + 70}{15} = \frac{889}{15} \approx 59,27 \text{ años}$$

- **Mediana**: valor central cuando los datos se ordenan.
Datos ordenados: 45, 48, 49, 52, 55, 55, 58, 59, 61, 63, 64, 67, 70, 71, 72.
Con 15 observaciones, la mediana es el 8.º valor: **59 años**.
- **Moda**: valor que más se repite. La edad 55 aparece dos veces; las demás, una. La distribución es unimodal (moda = **55**).

Interpretación: el centro de la distribución se sitúa alrededor de los 59 años, con una ligera asimetría porque la media es muy cercana a la mediana.

3.2 Medidas de dispersión y estimación

Miden la variabilidad o esparcimiento de los datos.

- **Rango**: $72 - 45 = 27$ años.
- **Varianza muestral** (s^2): calculando las desviaciones respecto a la media y sus cuadrados se obtiene:

$$s^2 \approx 79,35$$

- **Desviación estándar muestral** (s): $\sqrt{79,35} \approx 8,91$ años.

- **Rango intercuartílico (IQR):**

- Cuartil 1 (Q_1) = mediana de la primera mitad (45 a 58): **52 años**.
- Cuartil 3 (Q_3) = mediana de la segunda mitad (61 a 72): **67 años**.
- $IQR = Q_3 - Q_1 = 67 - 52 = 15$ años.

Estas medidas indican que, en promedio, las edades se desvían unos 8.9 años de la media, y que el 50 % central de los datos se concentra en un intervalo de 15 años.

Estimación: a partir de esta muestra, la media muestral (59.27) puede servir como estimador puntual de la media poblacional. El error estándar de la media es

$$\frac{s}{\sqrt{n}} = \frac{8,91}{\sqrt{15}} \approx 2,30 \text{ años.}$$

3.3 Histograma de frecuencia

Un histograma agrupa los datos en intervalos (bins) y muestra la frecuencia de valores en cada uno. Para el ejemplo, definimos intervalos de amplitud 10 años:

Intervalo (años)	Frecuencia
40 – 50	4
50 – 60	5
60 – 70	4
70 – 80	2

El histograma muestra una distribución aproximadamente simétrica con una ligera concentración en el intervalo central (50-60) y colas que se reducen hacia los extremos. No se observan vacíos ni picos abruptos.

3.4 Diagrama de tallo y hojas (stem-and-leaf)

Este gráfico conserva los valores originales y a la vez muestra la forma de la distribución. Se toma el tallo como la decena y la hoja como la unidad.

```

Tallo | Hojas
4     | 5 8 9
5     | 2 5 5 8 9
6     | 1 3 4 7
7     | 0 1 2

```

Clave: 4|5 significa 45.

Se aprecia la misma concentración en los 50 y la dispersión hasta los 70. La ventaja es que se pueden reconstruir exactamente los datos originales y detectar valores atípicos (en este caso no los hay evidentes).

3.5 Diagrama de caja (box-plot)

Construido a partir de los cuartiles:

- Línea inferior del bigote: mínimo = 45.
- Borde inferior de la caja: $Q_1 = 52$.
- Línea interior de la caja: mediana = 59.
- Borde superior de la caja: $Q_3 = 67$.
- Línea superior del bigote: máximo = 72.

No hay valores atípicos, ya que ningún dato queda fuera de los límites

$$Q_1 - 1,5 \times IQR = 52 - 22,5 = 29,5 \quad \text{y} \quad Q_3 + 1,5 \times IQR = 67 + 22,5 = 89,5.$$

El diagrama de caja muestra una caja ligeramente más larga hacia la parte superior ($Q_3 - \text{mediana} = 8$ años) que hacia la inferior ($\text{mediana} - Q_1 = 7$ años), indicando una asimetría positiva muy leve. Los bigotes tienen longitudes parecidas, confirmando una distribución bastante simétrica.

4 Conclusión

La aplicación conjunta de la estadística descriptiva y el marco CRISP-DM garantiza una comprensión profunda de los datos antes de cualquier modelado. Las medidas de tendencia central, dispersión y los gráficos exploratorios (histograma, tallo-hojas, diagrama de caja) permiten detectar valores atípicos, evaluar la simetría, identificar posibles transformaciones necesarias y documentar la calidad de la información; todo ello es parte indispensable de la fase de comprensión de los datos en CRISP-DM.