



Ramas de la computación en las que se basa la minería de datos

José Emmanuel Muñoz de Jesús

Benemérita Universidad Autónoma de Puebla

Materia: Minería de Datos

13 de mayo de 2026



1 Introducción

La minería de datos no es una disciplina aislada, sino un campo interdisciplinario que se construye sobre los cimientos de varias ramas de las ciencias de la computación. Su objetivo de extraer conocimiento útil de grandes volúmenes de datos exige la integración de técnicas y principios de bases de datos, inteligencia artificial, estadística computacional, computación de alto rendimiento y visualización, entre otras. A continuación se describe cada una de estas ramas y se explica cómo contribuyen al proceso de minería de datos.

2 Bases de datos y almacenamiento de la información

La minería de datos trabaja con datos que, en la mayoría de los casos, residen en sistemas de bases de datos. Esta rama aporta:

- **Modelado de datos y diseño de esquemas:** comprender cómo están estructurados los datos (relacional, dimensional, NoSQL) es indispensable para formular consultas eficientes y para la fase de comprensión de los datos (CRISP-DM).
- **Lenguajes de consulta (SQL, MDX, etc.):** la extracción, agregación y filtrado de datos se apoya en estos lenguajes. Gran parte de la preparación de datos se realiza directamente en el motor de base de datos antes de pasar a herramientas analíticas.
- **Sistemas de gestión de bases de datos (SGBD):** proveen mecanismos de indexación, optimización de consultas, transaccionalidad y seguridad que permiten manejar datos a escala empresarial.
- **Almacenes de datos (Data Warehousing) y datamarts:** son la fuente habitual para proyectos de minería. Incluyen procesos ETL (extracción, transformación y carga), limpieza e integración de datos de múltiples fuentes.
- **Bases de datos NoSQL y Big Data:** ante el volumen, velocidad y variedad de los datos actuales, la minería de datos se apoya en tecnologías como Hadoop HDFS, HBase, Cassandra, MongoDB, que permiten almacenar y procesar datos no estructurados o semiestructurados.

Sin una gestión eficiente del almacenamiento, la minería de datos sería inviable sobre conjuntos masivos.

3 Inteligencia artificial y aprendizaje automático

La inteligencia artificial (IA) es la rama que más directamente se asocia con la minería de datos, hasta el punto de que muchos consideran la minería de datos como un paso dentro del flujo de la IA aplicada.

- **Aprendizaje automático (Machine Learning):** proporciona los algoritmos de clasificación, regresión, agrupamiento y detección de anomalías. Técnicas como árboles de decisión, máquinas de soporte vectorial, redes neuronales y métodos bayesianos son compartidas por ambas disciplinas.

- **Aprendizaje profundo (Deep Learning):** maneja datos complejos (imágenes, texto, audio) con arquitecturas como redes convolucionales, recurrentes y transformadores, ampliando el alcance de la minería de datos a fuentes no estructuradas.
- **Procesamiento del lenguaje natural (PLN):** rama de la IA que permite la minería de texto, análisis de sentimientos, extracción de entidades y modelado de tópicos.
- **Visión artificial:** habilita la extracción de características de imágenes y videos, necesaria en minería de datos multimedia.
- **Razonamiento automatizado y sistemas expertos:** aunque menos frecuentes, pueden usarse para interpretar los patrones encontrados y generar alertas o recomendaciones.

La IA aporta los modelos predictivos y descriptivos, mientras que la minería de datos se encarga de preparar el terreno y evaluar los resultados en contexto.

4 Estadística computacional y análisis de datos

La estadística proporciona el lenguaje formal para describir y validar los hallazgos. En su vertiente computacional, se ocupa de algoritmos escalables para el análisis numérico.

- **Estadística descriptiva:** medidas de tendencia central, dispersión, histogramas, diagramas de caja y de tallo-hojas. Es la base del análisis exploratorio de datos (EDA).
- **Inferencia estadística:** pruebas de hipótesis, intervalos de confianza y métodos de remuestreo (bootstrap) permiten evaluar la significancia de los patrones y comparar modelos.
- **Modelado probabilístico:** distribuciones de probabilidad, modelos de mezclas y métodos bayesianos son fundamentales para agrupamiento y clasificación probabilística.
- **Diseño experimental y muestreo:** técnicas para seleccionar subconjuntos representativos y para validar que los resultados no sean producto del azar.
- **Métodos de reducción de dimensionalidad:** análisis de componentes principales (PCA), análisis factorial y escalado multidimensional, que ayudan a visualizar y simplificar datos de alta dimensión.

Mientras que la IA se centra en la predicción, la estadística enfatiza la explicación y la certeza de las conclusiones.

5 Computación de alto rendimiento y sistemas distribuidos

El volumen de datos actual exige infraestructuras que permitan procesarlos en tiempos razonables.

- **Procesamiento paralelo y distribuido:** frameworks como Apache Hadoop (MapReduce) y Apache Spark posibilitan el procesamiento de datos a escala de terabytes o petabytes dividiendo las tareas en nodos de un clúster.
- **Computación en GPU y TPU:** acelera algoritmos de aprendizaje profundo y de álgebra lineal, reduciendo tiempos de entrenamiento de días a horas o minutos.
- **Arquitecturas en la nube:** plataformas como AWS, Google Cloud y Azure ofrecen servicios gestionados de almacenamiento y procesamiento masivo (Amazon EMR, Google Dataproc, Azure HDInsight) que facilitan la ejecución de proyectos de minería de datos sin invertir en hardware propio.
- **Optimización de algoritmos:** técnicas de computación científica para resolver problemas de optimización convexa y combinatoria (descenso de gradiente estocástico, algoritmos de búsqueda) son el núcleo de muchos modelos de aprendizaje.

Sin esta rama, los métodos de minería de datos se limitarían a conjuntos de datos modestos y carecerían de aplicabilidad industrial.

6 Visualización de datos e interacción humano-computadora

El conocimiento extraído debe ser comunicado de forma comprensible. La visualización es una rama que tiende puentes entre los datos y el usuario final.

- **Gráficos estadísticos:** histogramas, diagramas de dispersión, mapas de calor, gráficos de coordenadas paralelas, entre otros, para el análisis exploratorio.
- **Visualización interactiva:** herramientas como Tableau, Power BI o bibliotecas como D3.js y Plotly permiten al usuario explorar dinámicamente los datos y los resultados de los modelos.
- **Representación de modelos:** dendrogramas para agrupamiento jerárquico, grafos de redes bayesianas, curvas ROC y matrices de confusión para evaluar clasificadores.
- **Dashboards analíticos:** paneles que consolidan múltiples visualizaciones y facilitan el seguimiento de indicadores clave (KPIs) derivados de la minería de datos.
- **Interacción humano-computadora (HCI):** principios de usabilidad y percepción visual ayudan a diseñar interfaces que no abrumen al usuario y destaquen los hallazgos relevantes.

La visualización no solo sirve para presentar resultados, sino también para identificar problemas en los datos (valores atípicos, sesgos) durante las fases tempranas del proyecto.

7 Algoritmos y estructuras de datos

La eficiencia de cualquier técnica de minería depende de una implementación algorítmica sólida.

- **Algoritmos de búsqueda y ordenación:** base para encontrar vecinos cercanos (k-NN), construir índices (árboles KD, árboles R) y acelerar consultas por similitud.
- **Estructuras de datos avanzadas:** tablas hash, colas de prioridad (heaps), grafos y matrices dispersas son ubicuas en la implementación de algoritmos de agrupamiento, sistemas de recomendación y análisis de redes.
- **Algoritmos sobre grafos:** detección de comunidades, cálculo de centralidad, caminos mínimos, fundamentales en minería de redes sociales y análisis de enlaces.
- **Técnicas de compresión y reducción de datos:** muestreo, sketching y hashing sensible a la localidad (LSH) permiten trabajar con conjuntos masivos reduciendo su dimensionalidad o su tamaño.

Un conocimiento profundo de esta rama permite adaptar o diseñar nuevos algoritmos cuando los existentes no escalan o no se ajustan al problema.

8 Sistemas de información y tecnologías web

En un contexto aplicado, la minería de datos a menudo se integra en sistemas de información más amplios.

- **Web scraping y APIs:** técnicas para recopilar datos de fuentes en línea (páginas web, redes sociales, repositorios abiertos) que luego alimentan el proceso de minería.
- **Stream processing:** herramientas como Apache Kafka o Flink para minar datos en tiempo real (series temporales, sensores IoT, transacciones financieras).
- **Integración de sistemas:** middleware y servicios web que permiten desplegar modelos de minería como parte de aplicaciones empresariales (por ejemplo, un motor de recomendaciones en un e-commerce).
- **Ciberseguridad:** detección de intrusiones y anomalías mediante modelos de minería de datos aplicados a registros de actividad.

Esta rama conecta los algoritmos con el mundo real, cerrando el ciclo desde la adquisición del dato hasta la acción.

9 Conclusión

La minería de datos es un crisol donde se funden múltiples ramas de la computación. De las bases de datos toma la capacidad de gestionar información a gran escala; de la inteligencia artificial, los algoritmos que aprenden patrones; de la estadística, la rigurosidad en la inferencia; de la computación de alto rendimiento, la potencia para procesar volúmenes masivos; de la visualización, la claridad para comunicar resultados; de los algoritmos, la eficiencia; y de los sistemas de información, la integración en entornos productivos. Esta naturaleza interdisciplinaria es lo que convierte a la minería de datos en una herramienta tan poderosa y versátil.