



Redes Bayesianas: Modelos Gráficos Probabilísticos para la Inferencia y la Causalidad

José Emmanuel Muñoz de Jesús

Benemérita Universidad Autónoma de Puebla

Materia: Minería de Datos

13 de mayo de 2026



1 ¿Qué es una red bayesiana?

Una **red bayesiana** (también llamada *red de creencia*, *red probabilística causal* o *diagrama de influencia*) es un modelo gráfico que representa las relaciones de dependencia e independencia condicional entre un conjunto de variables aleatorias. Es un grafo dirigido acíclico (DAG) donde:

- **Nodos:** representan variables. Pueden ser discretas (por ejemplo, *fuma: sí/no*) o continuas.
- **Arcos dirigidos (flechas):** indican dependencia probabilística directa. Si hay un arco de A a B , decimos que A es *padre* de B y que B depende condicionalmente de A .
- **Tablas de Probabilidad Condicional (CPT):** cada nodo tiene asociada una distribución de probabilidad local que cuantifica el efecto de sus padres. Para nodos sin padres, se usa una probabilidad a priori.

Formalmente, una red bayesiana con nodos $X_1, X_2, \dots, X_n$ define una distribución de probabilidad conjunta que se factoriza como:

$$P(X_1, X_2, \dots, X_n) = \prod_{i=1}^n P(X_i \mid \text{Padres}(X_i))$$

Esta factorización reduce drásticamente el número de parámetros necesarios y permite realizar inferencia eficiente, incluso con muchas variables.

2 Componentes y funcionamiento básico

2.1 Estructura (el grafo)

La estructura codifica las **independencias condicionales** que se asumen en el dominio. Si dos variables están separadas por un nodo intermedio, pueden volverse independientes condicionalmente dado ese nodo. El criterio estándar para leer independencias en un DAG es la **d-separación**.

2.2 Parámetros (las tablas de probabilidad condicional)

Para cada variable se especifica cuál es su probabilidad dados los valores de sus padres. Por ejemplo, en una red médica sencilla con las variables binarias *Fumar* (F), *Cáncer de pulmón* (C) y *Tos* (T):

- $P(F = \text{sí}) = 0,3$
- $P(C = \text{sí} \mid F = \text{sí}) = 0,1, \quad P(C = \text{sí} \mid F = \text{no}) = 0,01$
- $P(T = \text{sí} \mid C = \text{sí}) = 0,8, \quad P(T = \text{sí} \mid C = \text{no}) = 0,1$

La factorización es: $P(F, C, T) = P(F) \cdot P(C \mid F) \cdot P(T \mid C)$. La estructura gráfica ($F \rightarrow C \rightarrow T$) implica que, dado C , F y T son independientes (no hay arco directo entre F y T).

2.3 Inferencia probabilística

Una vez construida la red, podemos hacer **consulta de cualquier probabilidad condicional**. Dada evidencia (por ejemplo, sabemos que el paciente tiene tos, $T = \text{sí}$), se puede inferir la probabilidad de que fume o tenga cáncer. Los algoritmos más comunes son:

- **Inferencia exacta** por variable eliminación o árbol de uniones (*junction tree*).
- **Métodos aproximados** (Monte Carlo por Cadenas de Markov, muestreo de rechazo) cuando la red es demasiado grande.

Ejemplo numérico: Calculemos $P(F = \text{sí} \mid T = \text{sí})$ usando las tablas dadas. Aplicamos el teorema de Bayes encadenando la estructura:

$$P(F = \text{sí} \mid T = \text{sí}) = \frac{\sum_c P(F = \text{sí})P(C = c \mid F = \text{sí})P(T = \text{sí} \mid C = c)}{P(T = \text{sí})}$$

Los cálculos dan aproximadamente 0,231. Así, la probabilidad de que un paciente con tos sea fumador pasa del 30 % a priori a cerca del 23 %, porque la tos se explica principalmente por el cáncer, y el cáncer es poco frecuente incluso en fumadores.

3 Construcción de una red bayesiana

Se puede hacer de dos maneras:

- **Manual (basada en conocimiento experto):** un especialista define la estructura y estima las probabilidades condicionales.
- **Automática (aprendizaje de estructura y parámetros):** a partir de datos, se pueden aprender ambos. Existen algoritmos de aprendizaje:
 - **De parámetros:** cuando la estructura es conocida, basta estimar las CPTs mediante conteos de frecuencia (máxima verosimilitud o estimación bayesiana).
 - **De estructura:** se busca el grafo que mejor se ajusta a los datos usando puntuaciones como BIC, AIC o puntuación bayesiana y heurísticas de búsqueda (K2, hill-climbing, PC, etc.).

En minería de datos, las redes bayesianas se usan como clasificadores (Naive Bayes, TAN, redes generales) y como modelos para descubrir relaciones de dependencia.

4 Redes bayesianas complejas: grafos de causa-efecto

Cuando se habla de “**redes bayesianas complejas (grafos de causa-efecto)**”, se alude a los modelos que incorporan explícitamente el concepto de **causalidad**, no solo asociación probabilística. La teoría fue desarrollada por Judea Pearl, quien dotó a las redes bayesianas de un cálculo causal.

4.1 De la asociación a la intervención

Una red bayesiana estándar responde preguntas del tipo “¿qué probabilidad hay de que una variable tome cierto valor si observamos otra?”. Pero en muchas aplicaciones interesa la **causalidad**: “¿qué ocurre si intervenimos activamente y fijamos el valor de una variable?”. Esto se formaliza con el operador $\text{do}()$: $P(Y \mid \text{do}(X = x))$ denota la distribución de Y cuando forzamos X a tomar el valor x , rompiendo la influencia de las causas normales de X .

En un grafo causal (que es una red bayesiana con arcos que representan *influencias causales directas*), el efecto de una intervención se calcula eliminando todos los arcos que entran a la variable intervenida y reemplazando su distribución por un valor fijo. Este es el llamado **principio de “cirugía gráfica”** o *truncamiento*.

Ejemplo: en el modelo $F \rightarrow C \rightarrow T$, la intervención $\text{do}(F = \text{sí})$ (obligar a todos a fumar) corta cualquier influencia anterior sobre F , quedando el grafo modificado sin padres para F , y el cálculo se reduce a:

$$P(C, T \mid \text{do}(F = \text{sí})) = P(C \mid F = \text{sí})P(T \mid C)$$

Esto difiere de la mera observación condicional $P(C, T \mid F = \text{sí})$, donde se mantiene la posibilidad de que factores de confusión ocultos sesguen la asociación.

4.2 Contrafactuales y la escalera de la causalidad

Pearl distingue tres niveles de razonamiento causal:

1. **Asociación:** ver y observar ($P(y \mid x)$). Típico de las redes bayesianas clásicas.
2. **Intervención:** hacer, manipular ($P(y \mid \text{do}(x))$). Requiere un modelo causal y permite predecir el efecto de acciones.
3. **Contrafactuales:** imaginar, razonar sobre mundos hipotéticos (“¿qué habría pasado si el paciente no hubiera fumado, dado que fumó y desarrolló cáncer?”). Esto implica combinar observación e intervención en un mismo individuo y necesita variables latentes y el marco de los **modelos causales estructurales (SCM)**.

Los grafos de causa-efecto complejos son aquellos que incluyen variables latentes no observables (para representar confusores) y sobre los que se puede realizar inferencia causal usando el **cálculo-do** (do-calculus) y los criterios de puerta trasera (*back-door*) y puerta delantera (*front-door*).

4.3 Aplicaciones de las redes causales

- **Epidemiología y medicina:** estimar el efecto de un tratamiento controlando confusores observados y no observados.
- **Econometría y políticas públicas:** evaluar el impacto de intervenciones (cambios de precios, leyes) usando datos observacionales.
- **Inteligencia artificial explicable:** permitir que un agente razone sobre “qué pasaría si” y tome decisiones robustas.

5 Relación con minería de datos y machine learning

Las redes bayesianas son una herramienta poderosa porque:

- Manejan la incertidumbre de manera natural.
- Incorporan conocimiento experto a través de la estructura y las probabilidades a priori.
- Permiten trabajar con datos incompletos usando algoritmos EM para estimar parámetros con valores faltantes.
- Son interpretables: la topología del grafo ofrece una representación visual de las dependencias, lo que las hace útiles para el análisis exploratorio y la comprensión del dominio, complementando la fase de comprensión de datos de CRISP-DM.

En el contexto de la tarea anterior, las redes bayesianas pueden aplicarse en las fases de modelado y evaluación, o incluso en la comprensión del negocio para mapear factores que influyen en un evento de interés.

6 Conclusión

Las redes bayesianas son mucho más que meros clasificadores probabilísticos. En su forma más elaborada, constituyen **grafos de causa-efecto** que permiten pasar de la correlación a la predicción de intervenciones y contrafactuales. Este potencial las convierte en un instrumento esencial en la minería de datos actual, especialmente en ámbitos donde la explicabilidad y la inferencia causal son imprescindibles.