



Resumen de las tareas sobre Minería de Datos

José Emmanuel Muñoz de Jesús

Benemérita Universidad Autónoma de Puebla

Materia: Minería de Datos

13 de mayo de 2026



1 Introducción

A lo largo del diálogo se plantearon múltiples consignas relacionadas con la minería de datos, el aprendizaje automático y la inteligencia artificial. Estas tareas abarcan desde fundamentos estadísticos y modelos probabilísticos hasta programación y edición académica. A continuación se agrupan y sintetizan todas ellas, indicando el enfoque de cada una y su vínculo con la materia.

2 Tareas sobre modelos probabilísticos y bayesianos

2.1 Teorema de Bayes y clasificadores bayesianos

Descripción: Explicar el uso del teorema de Bayes en minería de datos y machine learning, profundizando en los clasificadores bayesianos y su implementación en Python.

Objetivo: Comprender cómo se aplica la inferencia probabilística para clasificar datos y cómo se materializa en bibliotecas como scikit-learn.

2.2 Redes bayesianas y causalidad

Descripción: Definir qué son las redes bayesianas y abordar las redes bayesianas complejas (grafos de causa-efecto), incluyendo inferencia causal, operador *do()* y niveles de razonamiento de Pearl.

Objetivo: Dominar los modelos gráficos probabilísticos y su extensión hacia la causalidad, esenciales para el análisis de dependencias y la toma de decisiones.

3 Tareas sobre agrupamiento y particionamiento

3.1 Agrupamiento, aprendizaje supervisado y no supervisado, y modelo de partición discreta

Descripción: Describir cómo se agrupan y particionan los datos, diferenciar aprendizaje supervisado y no supervisado, y relacionarlo con el modelo de partición discreta.

Objetivo: Asentar las bases del análisis de clústeres y su formalización matemática como particiones de un conjunto.

3.2 Estudio del particionamiento jerárquico y no jerárquico

Descripción: Argumentar por qué es relevante estudiar ambos tipos de agrupamiento, señalando ventajas, limitaciones y escenarios de aplicación.

Objetivo: Justificar la inclusión de estos métodos en la formación de un minero de datos y destacar su complementariedad.

3.3 Partición matemática y partición discreta en agrupamiento

Descripción: Formalizar el concepto de partición matemática, definir la partición discreta (pertenencia binaria) y conectarlo con el agrupamiento particional y la noción de distancia.

Objetivo: Dotar de rigor matemático a la idea de “modelo de participación discreta”, cerrando la brecha entre la teoría de conjuntos y los algoritmos como k-medias.

4 Tareas sobre fundamentos de estadística y metodología

4.1 Estadística descriptiva y herramientas exploratorias

Descripción: Definir qué es la estadística y detallar, para un conjunto de datos, las medidas de tendencia central, estimación, dispersión, diagrama de caja, diagrama de tallo y hojas, e histograma de frecuencia.

Objetivo: Dominar las técnicas de análisis exploratorio que se emplean en la fase de comprensión de datos de CRISP-DM.

4.2 Metodología CRISP-DM

Descripción: Explicar en qué consiste la metodología CRISP-DM (Cross-Industry Standard Process for Data Mining), detallando sus seis fases y el papel de la estadística en cada una.

Objetivo: Conocer el marco de trabajo estándar para proyectos de minería de datos y saber situar las demás tareas dentro de él.

5 Tareas sobre inteligencia artificial y su relación con la minería de datos

5.1 Definición de inteligencia artificial y vínculo con minería de datos

Descripción: Explicar qué es la inteligencia artificial, cómo se relaciona con la minería de datos y por qué el aprendizaje automático actúa como puente entre ambas.

Objetivo: Clarificar la sinergia entre IA y minería de datos, mostrando que una alimenta a la otra en el ciclo de descubrimiento de conocimiento.

5.2 ¿Por qué estudiamos minería de datos?

Descripción: Exponer las razones académicas, profesionales y estratégicas que justifican dedicar tiempo al aprendizaje de la minería de datos.

Objetivo: Motivar el estudio de la disciplina y contextualizar su importancia en el mundo actual.

5.3 ¿Por qué estudiar el particionamiento?

Descripción: Argumentar la relevancia de estudiar específicamente el agrupamiento particional dentro del aprendizaje no supervisado.

Objetivo: Destacar su simplicidad, eficiencia, formalización matemática y aplicaciones prácticas como motivación para profundizar en el tema.

5.4 Resumen de todos los temas vistos

Descripción: Elaborar un resumen integrador que abarque los conceptos clave discutidos: minería de datos, IA, aprendizaje automático, agrupamiento, partición matemática y su interrelación.

Objetivo: Consolidar el aprendizaje global, demostrando cómo las distintas piezas encajan en un marco coherente.

6 Tareas complementarias (programación, edición y aplicación práctica)

6.1 Edición de documento a formato IEEE con LaTeX

Descripción: Convertir un borrador sobre el sector salud en México a un documento con formato IEEE, generando el código LaTeX correspondiente.

Objetivo: Practicar la escritura académica profesional y el uso de herramientas de composición científica.

6.2 Modificación de script de scraping en Python

Descripción: Ajustar un código de extracción de datos de Reddit para que procese bloques de 500 registros, guarde archivos JSON parciales y continúe hasta agotar los datos o recibir Ctrl+C.

Objetivo: Desarrollar habilidades de programación aplicada a la obtención y gestión de grandes volúmenes de datos, una fase clave en proyectos reales.

6.3 Análisis exploratorio de datos (EDA) e interpretación de resultados

Descripción: Integrar una sección de EDA a un proyecto, resolver errores de instalación, ejecutar el análisis sobre un corpus masivo, interpretar histogramas y boxplots, y redactar los hallazgos en un documento editable.

Objetivo: Aplicar de forma práctica las técnicas de estadística descriptiva y visualización, cerrando el ciclo de comprensión de datos según CRISP-DM.

7 Conclusión

Las tareas enumeradas constituyen un recorrido completo por los pilares de la minería de datos: desde la estadística descriptiva y la metodología de proyecto, pasando por los modelos probabilísticos y de agrupamiento, hasta la implementación práctica con código y la comunicación formal de resultados. En conjunto, cubren tanto los fundamentos teóricos como las competencias aplicadas que se esperan de un profesional en este campo.