

Manual de Usuario

Pipeline de Análisis de Opinión sobre la Vacuna de Influenza

Versión 1.0 · Abril 2026

1. ¿Qué hace este sistema?

Este pipeline analiza comentarios de Reddit para identificar y clasificar quejas ciudadanas sobre el sistema de salud público de México ante la influenza.

Al terminar, obtendrá:

- Una clasificación automática de comentarios en quejas graves o neutras.
- Un reporte con las fallas más frecuentes detectadas: tiempos de espera, desabasto, saturación, etc.
- Un tablero visual en HTML que puede abrir en cualquier navegador.

2. Requisitos

Antes de empezar, asegúrese de tener lo siguiente:

- Python 3.10 o superior instalado en su equipo.
- Conexión a internet (necesaria en el primer paso y para descargar los modelos de IA la primera vez).
- Al menos 8 GB de RAM disponibles.
- Aproximadamente 2 GB libres en disco para los modelos de inteligencia artificial.

3. Instalación

Abra una terminal y ejecute estos tres comandos, uno por uno. Solo necesita hacerlo una vez.

Instalar las librerías necesarias:

```
pip install requests emoji ijson spacy scikit-learn numpy scipy  
matplotlib pysentimiento torch sentence-transformers brotli zstandard
```

Descargar el modelo de lenguaje en español:

```
python -m spacy download es_core_news_sm
```

Los modelos de inteligencia artificial se descargan automáticamente la primera vez que ejecute los Pasos 4 y 6. Puede tardar varios minutos.

4. Ejecución del Pipeline

Coloque todos los scripts en la misma carpeta. Luego ejecútelos en este orden exacto desde su terminal. Cada script le pedirá que seleccione el archivo generado en el paso anterior.

1

python scraper_influenza_vacuna_v3.py

Recolecta comentarios de Reddit. Puede interrumpirlo con Ctrl+C cuando quiera; guardará todo lo recolectado.

2

python limpiar_dataset_vacuna_v6.py

Limpia el dataset: elimina bots, spam y comentarios irrelevantes.

3

python enriqueser.py

Añade métricas de análisis a cada comentario (nivel de queja, impacto, etc.).

4

python auto_etiquetar.py

Clasifica el sentimiento de cada comentario usando inteligencia artificial.

5

python normalizar_nlp_v3.py

Prepara los textos para el modelo: lematización y limpieza lingüística.

6

python vectorizar_v4.py

Convierte los textos en números. Elija la Estrategia E (Híbrida) cuando el script lo pregunte.

7

python analizar_v4.py

Entrena el clasificador y genera los reportes y gráficas de resultados.

8

python infografia_html.py

Genera el tablero visual. No necesita seleccionar archivos; los detecta solo.

5. Resultado Final

Al terminar el Paso 8, encontrará en su carpeta un archivo con este formato:

```
infografia_vacuna_v4_YYYYMMDD_HHMMSS.html
```

Ábralo con doble clic en cualquier navegador para ver el tablero completo con todos los resultados del análisis.

6. Problemas Frecuentes

«No se encontraron archivos» al seleccionar entrada

El archivo del paso anterior no está en la misma carpeta que los scripts. Asegúrese de que todo está en el mismo directorio.

El Paso 6 tarda demasiado

Si no tiene GPU, la Estrategia E puede ser lenta. Para hacer pruebas rápidas elija la Estrategia A; para resultados óptimos use la E.

El Paso 1 se interrumpe solo

Reddit puede bloquear temporalmente el scraper. Todo lo recolectado hasta ese momento ya fue guardado. Espere unos minutos y vuelva a ejecutarlo.

La infografía aparece en blanco

El Paso 7 debe haberse completado correctamente antes. Verifique que los archivos de reporte estén en la misma carpeta.